

گزارش فنی - بخش یادگیری ماشین

پروژه تشخیص تقلب در تراکنش‌ها (Fraud Detection)

تهیه شده برای: تیم بک‌اند

تاریخ: ۲۰ ژوئیه ۲۰۲۶ (۲۹ تیر ۱۴۰۵)

خلاصه اجرایی و پیشنهاد

سه مدل یادگیری ماشین برای شناسایی تراکنش‌های متقلبانه آموزش داده و با یکدیگر مقایسه شدند: رگرسیون لجستیک (به عنوان مدل پایه)، XGBoost و LightGBM. با توجه به عدم توازن شدید داده‌ها (نرخ تقلب در داده تست تنها حدود ۰.۱۷٪)، معیار اصلی ارزیابی، PR-AUC (میانگین دقت) و F1-score مربوط به کلاس تقلب در نظر گرفته شد، نه Accuracy کلی.

● مدل LightGBM با PR-AUC برابر با ۰.۸۲۰۱ روی داده تست، بهترین عملکرد کلی را در بین سه مدل ثبت کرد.

● با تنظیم آستانه تصمیم روی ۰.۱، مدل LightGBM به F1-score برابر با ۰.۸۳۸۰ می‌رسد که بالاترین مقدار در میان تمامی مدل‌ها و آستانه‌های بررسی شده در این گزارش است.

● مدل XGBoost عملکردی بسیار نزدیک دارد و با Precision برابر با ۰.۹۷۱۸، کمترین تعداد هشدار اشتباه (False Positive) — تنها ۲ مورد از ۵۶٬۷۴۶ تراکنش تست — را ثبت کرده است.

پیشنهاد: استقرار مدل LightGBM به عنوان مدل اصلی، با آستانه تصمیم قابل تنظیم (پیشنهاد اولیه: بین ۰.۱ تا ۰.۲۲) بسته به اولویت کسب و کار بین کاهش هشدار اشتباه و افزایش نرخ شناسایی تقلب. در صورتی که هزینه مسدودسازی اشتباه تراکنش سالم بسیار بالا باشد، XGBoost گزینه جایگزین مناسبی است. جزئیات کامل در بخش‌های بعدی و جمع‌بندی نهایی (بخش ۷) آمده است.

۱. مقدمه

هدف این بخش از پروژه، ساخت مدلی برای شناسایی تراکنش‌های متقلبانه در میان حجم بالای تراکنش‌های سالم است. مجموعه داده آزمون (Test Set) شامل ۵۶٬۷۴۶ تراکنش است که از این میان تنها ۹۵ مورد (معادل ۰.۱۷٪) متقلبانه و ۵۶٬۶۵۱ مورد باقی‌مانده سالم هستند.

این عدم توازن شدید باعث می‌شود معیارهایی مانند Accuracy گمراه‌کننده باشند؛ چراکه حتی مدلی که همه تراکنش‌ها را «سالم» پیش‌بینی کند نیز به Accuracy بالای ۹۹.۸٪ می‌رسد. به همین دلیل، معیارهای PR-AUC (Average Precision)، Precision، Recall و F1-score مربوط به کلاس تقلب، به عنوان معیارهای اصلی ارزیابی مدل‌ها انتخاب شدند.

- داده‌ها به دو بخش آموزش (Train) و آزمون نگه‌داشته‌شده (Held-out Test) تقسیم شدند. ارزیابی نهایی هر مدل تنها یک‌بار و روی داده آزمون (۵۶۷۴۶ نمونه) انجام شد که در فرایند آموزش و تنظیم ابرپارامتر مورد استفاده قرار نگرفته بود.
- برای مدل پایه (رگرسیون لجستیک)، از اعتبارسنجی متقاطع (Cross-Validation) روی داده آموزش استفاده شد.
- برای مدل‌های XGBoost و LightGBM، تنظیم ابرپارامترها با استفاده از کتابخانه Optuna و طی ۲۰ آزمایش (Trial) برای هر مدل انجام شد؛ تابع هدف بهینه‌سازی، بیشینه‌سازی میانگین PR-AUC روی فولدهای اعتبارسنجی متقاطع بود.
- به‌جای استفاده از آستانه پیش‌فرض ۰.۵ برای تبدیل احتمال خروجی به برچسب نهایی، برای هر مدل بهترین آستانه تصمیم با استفاده از پیش‌بینی‌های Out-of-Fold (OOF) روی داده آموزش و با هدف بیشینه‌سازی F1-score تعیین شد.

۳. مدل پایه: رگرسیون لجستیک (Logistic Regression)

۳.۱ نتایج اعتبارسنجی متقاطع (Cross-Validation)

معیار	Train [LRI] [PDI]	Validation (میانگین $\pm$ انحراف معیار) [LRI] [PDI]
[LRI] Accuracy [PDI]	[LRI] 0.9994 [PDI]	[LRI] 0.9994 ± 0.0001 [PDI]
[LRI] Precision [PDI]	[LRI] 0.8550 [PDI]	[LRI] 0.8474 ± 0.0385 [PDI]
[LRI] Recall [PDI]	[LRI] 0.7989 [PDI]	[LRI] 0.7909 ± 0.0715 [PDI]
[LRI] F1-score [PDI]	[LRI] 0.8259 [PDI]	[LRI] 0.8157 ± 0.0386 [PDI]
[LRI] ROC-AUC [PDI]	[LRI] 0.9867 [PDI]	[LRI] 0.9844 ± 0.0101 [PDI]
[LRI] PR-AUC (Average Precision) [PDI]	[LRI] 0.7871 [PDI]	[LRI] 0.7851 ± 0.0422 [PDI]

۳.۲ انتخاب آستانه تصمیم

بهترین آستانه (بر اساس پیش‌بینی‌های OOF، با هدف بیشینه‌سازی F1) : ۰.۴۹۱۸ — در این آستانه Precision برابر ۰.۸۴۳۶، Recall برابر ۰.۷۹۸۹ و F1-score برابر ۰.۸۲۰۷ به‌دست آمد.

۳.۳ ارزیابی نهایی روی داده تست

PR-AUC (تست): 0.7036 | Accuracy کلی: 0.9993

تعداد نمونه	F1-score	Recall	Precision	کلاس
56,651	0.9997	0.9998	0.9995	۰ (سالم)
95	0.7836	0.7053	0.8816	۱ (متقلبانہ)

ماتریس درهم‌ریختگی (Confusion Matrix):

	پیش‌بینی: متقلبانہ	پیش‌بینی: سالم
واقعی: سالم	9	56,642
واقعی: متقلبانہ	67	28

یادداشت: مدل نهایی این بخش در فایل `baseline_logreg.joblib` ذخیره و صادر شد.

۴. مدل XGBoost

۴.۱ تنظیم ابرپارامترها (Optuna — ۲۰ Trial)

بهترین نتیجه در Trial شماره ۱۱ حاصل شد. بهترین ابرپارامترهای یافت‌شده در جدول زیر آمده است:

مقدار بهینه	پارامتر
149	n_estimators
6	max_depth
0.1248	learning_rate
0.7110	subsample
0.7235	colsample_bytree
8	min_child_weight
0.1224	reg_lambda
571.41	scale_pos_weight
0.0378	gamma

بهترین PR-AUC روی اعتبارسنجی متقاطع (CV): 0.8523

۴.۲ انتخاب آستانه تصمیم

بهترین آستانه (بر اساس OOF، بیشینه‌سازی F_1): ۰.۹۴۲۷. این مقدار نسبتاً بالا نشان می‌دهد مدل XGBoost احتمالات را برای کلاس تقلب با اطمینان بیشتری تخصیص می‌دهد.

۴.۳ ارزیابی نهایی روی داده تست

PR-AUC (تست): 0.8110 | Accuracy کلی: 0.9995

تعداد نمونه	F1-score	Recall	Precision	کلاس
56,651	0.9998	1.0000	0.9995	۰ (سالم)
95	0.8313	0.7263	0.9718	۱ (متقلبانه)

ماتریس درهم‌ریختگی (Confusion Matrix):

	پیش‌بینی: سالم	پیش‌بینی: متقلبانه
واقعی: سالم	56,649	2
واقعی: متقلبانه	26	69

۵. مدل LightGBM

۵.۱ تنظیم ابرپارامترها (Optuna — ۲۰ Trial)

بهترین نتیجه در Trial شماره ۱۲ حاصل شد. بهترین ابرپارامترهای یافت‌شده در جدول زیر آمده است:

پارامتر	مقدار بهینه
n_estimators	169
num_leaves	96
learning_rate	0.2992
subsample	0.7174
colsample_bytree	0.7977
min_child_samples	43
reg_lambda	9.3364
max_depth	4

بهترین PR-AUC روی اعتبارسنجی متقاطع (CV): 0.8435

۵.۲ انتخاب آستانه تصمیم

بهترین آستانه (بر اساس OOF، بیشینه‌سازی F_1): ۰.۲۱۷۲. معیارهای OOF در این آستانه: F_1 -score برابر ۰.۸۶۳۱، Precision برابر ۰.۹۱۴۲ و Recall برابر ۰.۸۱۷۵.

۵.۳ ارزیابی نهایی روی داده تست (آستانه پیش‌فرض)

PR-AUC (تست): 0.8201 | Accuracy کلی: 0.9995

تعداد نمونه	F_1 -score	Recall	Precision	کلاس
56,651	0.9998	0.9999	0.9996	۰ (سالم)
95	0.8353	0.7474	0.9467	۱ (متقلبانه)

ماتریس درهم‌ریختگی (Confusion Matrix):

	پیش‌بینی: سالم	پیش‌بینی: متقلبانه
واقعی: سالم	56,647	4
واقعی: متقلبانه	24	71

۵.۴ تحلیل حساسیت به آستانه روی داده تست

به‌منظور بررسی سناریوهای مختلف، عملکرد مدل LightGBM در چند آستانه متفاوت روی داده تست ارزیابی شد:

آستانه	Precision (تقلب)	Recall (تقلب)	F_1 (تقلب)	Accuracy	F_1 (Macro avg)
0.1	0.8929	0.7895	0.8380	0.9995	0.9189
0.2	0.9342	0.7474	0.8304	0.9995	0.9151
0.217	—*	—*	—*	0.9995	0.9190

بهترین F_1 -score مربوط به کلاس تقلب در میان آستانه‌های بررسی‌شده، در آستانه ۰.۱ حاصل شد (۰.۸۳۸۰).

مدل	PR-AUC (CV) [LRI] [PDI]	PR-AUC (تست) [LRI] [PDI]	Precision [LRI] [PDI]	Recall [LRI] [PDI]	F1-score [LRI] [PDI]
رگرسیون لجستیک (Baseline)	[LRI] —* [PDI]	[LRI] 0.7036 [PDI]	[LRI] 0.8816 [PDI]	[LRI] 0.7053 [PDI]	[LRI] 0.7836 [PDI]
XGBoost [LRI] [PDI]	[LRI] 0.8523 [PDI]	[LRI] 0.8110 [PDI]	[LRI] 0.9718 [PDI]	[LRI] 0.7263 [PDI]	[LRI] 0.8313 [PDI]
LightGBM (آستانه پیش فرض)	[LRI] 0.8435 [PDI]	[LRI] 0.8201 [PDI]	[LRI] 0.9467 [PDI]	[LRI] 0.7474 [PDI]	[LRI] 0.8353 [PDI]
LightGBM (آستانه ۰.۱)	[LRI] 0.8435 [PDI]	[LRI] 0.8201 [PDI]	[LRI] 0.8929 [PDI]	[LRI] 0.7895 [PDI]	[LRI] 0.8380 [PDI]

* برای مدل پایه، تنظیم ابرپارامتر با Optuna انجام نشد. مقدار معادل PR-AUC/اعتبارسنجی متقاطع آن، 0.7851 ± 0.0422 (بخش ۳.۱) است.

۷. جمع‌بندی و گام‌های بعدی

- مدل LightGBM بهترین تعادل بین Precision و Recall و بالاترین (۰.۸۳۸۰) F1-score را در میان تمامی مدل‌ها و آستانه‌های بررسی‌شده ارائه می‌دهد و به‌عنوان مدل پیشنهادی برای استقرار در محیط عملیاتی معرفی می‌شود.
- در صورتی که کاهش هشدارهای اشتباه (False Positive) اولویت بالاتری نسبت به شناسایی حداکثری تقلب داشته باشد (مثلاً به دلیل هزینه بالای مسدودسازی تراکنش مشتریان سالم)، مدل XGBoost با Precision برابر ۰.۹۷۱۸ و تنها ۲ هشدار اشتباه از ۵۶٬۷۴۶ تراکنش تست، گزینه مناسب‌تری است.
- مدل رگرسیون لجستیک با وجود سادگی و سرعت بالا در Inference، عملکرد ضعیف‌تری (PR-AUC: ۰.۷۰۳۶) نسبت به دو مدل درختی داشت و برای استقرار نهایی پیشنهاد نمی‌شود؛ می‌تواند صرفاً به‌عنوان Benchmark یا Fallback در نظر گرفته شود.
- گام بعدی: صادرات (Export) مدل‌های نهایی XGBoost و LightGBM مشابه baseline_logreg.joblib و آماده‌سازی برای یکپارچه‌سازی با سرویس بک‌اند، همراه با مستندسازی فرمت ورودی (ویژگی‌ها) و خروجی (احتمال/برچسب) مدل.
- پیشنهاد می‌شود آستانه تصمیم به‌صورت یک پارامتر قابل‌تنظیم (Config) در سرویس پیاده‌سازی شود تا بدون نیاز به آموزش مجدد مدل، بتوان تعادل Precision/Recall را متناسب با نیاز کسب‌وکار تغییر داد.